Water Quality

Drinking water potability

Alperen Uslu
20110131048

Veri Seti Hakkında

Güvenli içme suyuna erişim sağlık için esastır, temel bir insan hakkıdır ve sağlığın korunmasına yönelik etkin politikanın bir bileşenidir. Bu, ulusal, bölgesel ve yerel düzeyde bir sağlık ve kalkınma sorunu olarak önemlidir. Bazı bölgelerde, su temini ve sanitasyona yapılan yatırımların net bir ekonomik fayda sağlayabileceği gösterilmiştir, çünkü olumsuz sağlık etkileri ve sağlık bakım maliyetlerindeki azalmalar, müdahaleleri üstlenmenin maliyetlerinden daha fazladır.

water_potability.csv dosyası, 3276 farklı su kütlesi için su kalitesi ölçümlerini içerir.

Veri Seti Özellikleri Hakkında

1. pH değeri:

PH, suyun asit-baz dengesini değerlendirmede önemli bir parametredir. Aynı zamanda su durumunun asidik veya alkali durumunun göstergesidir. DSÖ, izin verilen maksimum pH sınırını 6,5 ila 8,5 arasında önermiştir. Mevcut araştırma aralıkları, DSÖ standartları aralığında olan 6,52–6,83 idi.

2. Sertlik:

Sertlik esas olarak kalsiyum ve magnezyum tuzlarından kaynaklanır. Bu tuzlar, suyun içinden geçtiği jeolojik tortulardan çözülür. Suyun sertlik oluşturan malzeme ile temas halinde olduğu süre, ham suda ne kadar sertlik olduğunu belirlemeye yardımcı olur. Sertlik başlangıçta suyun Kalsiyum ve Magnezyumun neden olduğu sabunu çökeltme kapasitesi olarak tanımlanıyordu.

Veri Seti Özellikleri Hakkında

3. Katılar (Toplam çözünmüş katılar - TDS):

Su, çok çeşitli inorganik ve bazı organik mineralleri veya potasyum, kalsiyum, sodyum, bikarbonatlar, klorürler, magnezyum, sülfatlar vb. Bu, su kullanımı için önemli bir parametredir. TDS değeri yüksek olan su, suyun yüksek oranda mineralize olduğunu gösterir. TDS için arzu edilen limit 500 mg/l ve maksimum limit 1000 mg/l olup içme amaçlı reçete edilmiştir.

4. Kloraminler:

Klor ve kloramin, kamusal su sistemlerinde kullanılan başlıca dezenfektanlardır. Kloraminler en yaygın olarak içme suyunu arıtmak için klora amonyak eklendiğinde oluşur. Litre başına 4 miligrama kadar klor seviyeleri (mg).

Veri Seti Özellikleri Hakkında

5. Sülfat:

Sülfatlar, minerallerde, toprakta ve kayalarda bulunan doğal olarak oluşan maddelerdir. Ortam havasında, yeraltı sularında, bitkilerde ve yiyeceklerde bulunurlar. Sülfatın başlıca ticari kullanımı kimya endüstrisindedir. Deniz suyundaki sülfat konsantrasyonu litre başına yaklaşık 2.700 miligramdır (mg/L). Bazı coğrafi bölgelerde çok daha yüksek konsantrasyonlar (1000 mg/L) bulunmasına rağmen, çoğu tatlı su kaynağında 3 ila 30 mg/L arasında değişir.

6. İletkenlik:

Saf su, elektrik akımını iyi bir şekilde iletmez, aksine iyi bir yalıtkandır. İyon konsantrasyonundaki artış, suyun elektriksel iletkenliğini arttırır. Genel olarak, suda çözünmüş katıların miktarı elektriksel iletkenliği belirler. Elektriksel iletkenlik (EC), aslında bir çözeltinin akım iletmesini sağlayan iyonik sürecini ölçer. WHO standartlarına göre EC değeri 400 μS/cm'yi geçmemelidir.

Veri Seti Özellikleri Hakkında

7. Organik_karbon:

Kaynak sularındaki Toplam Organik Karbon (TOC), sentetik kaynakların yanı sıra çürüyen doğal organik maddelerden (NOM) gelir. TOC, saf sudaki organik bileşiklerdeki toplam karbon miktarının bir ölçüsüdür. US EPA'ya göre TOC olarak arıtılmış / içme suyunda < 2 mg/L ve arıtma için kullanılan kaynak suda < 4 mg/Lit.

8. Trihalometanlar:

THM'ler, klor ile işlenmiş suda bulunabilen kimyasallardır. İçme suyundaki THM'lerin konsantrasyonu, sudaki organik madde seviyesine, suyu arıtmak için gereken klor miktarına ve arıtılan suyun sıcaklığına göre değişir. 80 ppm'e kadar THM seviyeleri içme suyunda güvenli kabul edilir.

Veri Seti Özellikleri Hakkında

9. Bulanıklık:

Suyun bulanıklığı, askıda halde bulunan katı madde miktarına bağlıdır. Suyun ışık yayma özelliklerinin bir ölçüsüdür ve test koloidal maddeye göre atık deşarj kalitesini belirtmek için kullanılır. Wondo Genet Campus için elde edilen ortalama bulanıklık değeri (0,98 NTU), DSÖ tarafından tavsiye edilen 5,00 NTU değerinden düşüktür.

10. İçilebilirlik:

Suyun insan tüketimi için güvenli olup olmadığını gösterir; 1, İçilebilir anlamına gelir ve 0, İçilemez anlamına gelir.

Veri Kümesini Aktarma

- Veri setini yüklemek için pandas kullanıyoruz.
- import pandas as pd
- Veri setini df degiskenine atayalım.
- df=pd.read_csv("water_potability.csv")
- Sonra veri setinin ilk 5 satırına bakalım
- df.head()
-

	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
0	NaN	204.890455	20791.318981	7.300212	368.516441	564.308654	10.379783	86.990970	2.963135	0
1	3.716080	129.422921	18630.057858	6.635246	NaN	592.885359	15.180013	56.329076	4.500656	0
2	8.099124	224.236259	19909.541732	9.275884	NaN	418.606213	16.868637	66.420093	3.055934	0
3	8.316766	214.373394	22018.417441	8.059332	356.886136	363.266516	18.436524	100.341674	4.628771	0
4	9.092223	181.101509	17978.986339	6.546600	310.135738	398.410813	11.558279	31.997993	4.075075	0

- Seaborn istatistiksel grafikleri çizdirmek için kullanıyoruz.
- import seaborn as sns
- İçilebilirlik ve içilemezlik oranına bakıyoruz.
- sns.countplot(x="Potability",data=df)
-

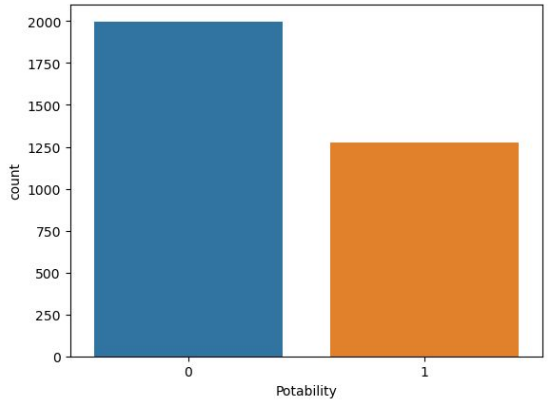

- ph sıklığına bakmak içinde
- df["ph"].plot.hist()
-

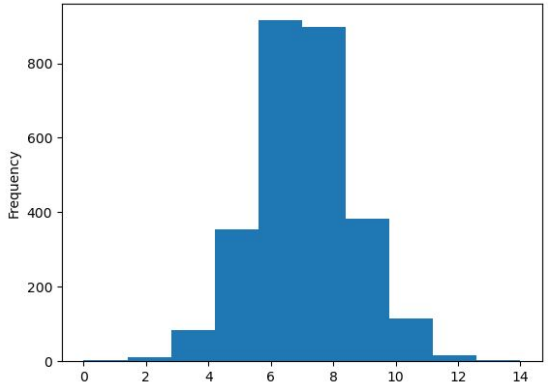

- Boş değer olup olmadığına kontrol ediyoruz.
- df.isnull().sum()

```
ph                 491
Hardness             0
Solids               0
Chloramines          0
Sulfate            781
Conductivity         0
Organic_carbon       0
Trihalomethanes    162
Turbidity            0
Potability           0
dtype: int64
```

- Isı haritasıyla nerelerde null degerler olduguna bakıyoruz.
- sns.heatmap(df.isnull(),yticklabels=False,cmap="viridis)
-

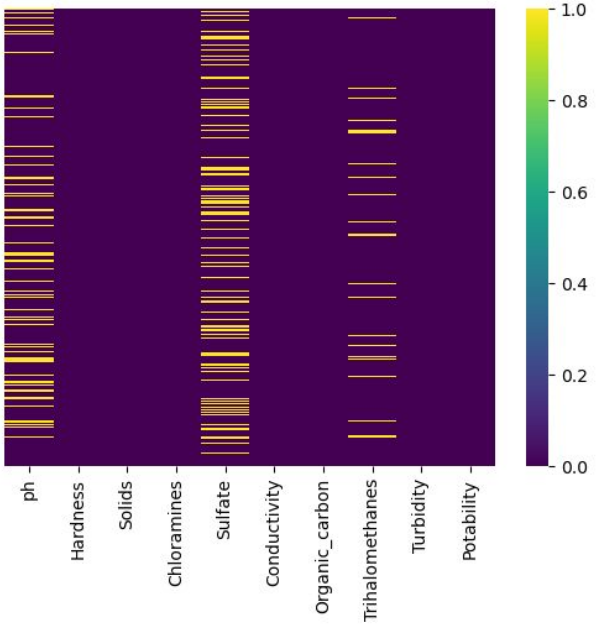

- Null olan değerlere ortalama atadık
- df.fillna(df.mean(),inplace=True)

	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
0	7.080795	204.890455	20791.318981	7.300212	368.516441	564.308654	10.379783	86.990970	2.963135	0
1	3.716080	129.422921	18630.057858	6.635246	333.775777	592.885359	15.180013	56.329076	4.500656	0
2	8.099124	224.236259	19909.541732	9.275884	333.775777	418.606213	16.868637	66.420093	3.055934	0
3	8.316766	214.373394	22018.417441	8.059332	356.886136	363.266516	18.436524	100.341674	4.628771	0
4	9.092223	181.101509	17978.986339	6.546600	310.135738	398.410813	11.558279	31.997993	4.075075	0

- Aykırı değerleri bulmak için
- from sklearn.neighbors import LocalOutlierFactor kullanıyoruz
- Bazı kodlardan sonra sonuç aşağıdaki gibi aykırı değerler çıkıyor

	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
1031	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
1068	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
1186	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
1537	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
1554	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2134	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2602	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2704	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2718	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2737	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
2906	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
3149	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
3150	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1
3161	6.60254	174.632977	21607.483238	6.581327	308.931421	657.570422	9.064445	68.827047	3.592496	1

- Son durumda verimiz aşağıdaki gibidir.

	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
0	7.080795	204.890455	20791.318981	7.300212	368.516441	564.308654	10.379783	86.990970	2.963135	0
1	3.716080	129.422921	18630.057858	6.635246	333.775777	592.885359	15.180013	56.329076	4.500656	0
2	8.099124	224.236259	19909.541732	9.275884	333.775777	418.606213	16.868637	66.420093	3.055934	0
3	8.316766	214.373394	22018.417441	8.059332	356.886136	363.266516	18.436524	100.341674	4.628771	0
4	9.092223	181.101509	17978.986339	6.546600	310.135738	398.410813	11.558279	31.997993	4.075075	0

- Veri seti hakkinda bilgiler
- df.info() bakıyoruz
-
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3276 entries, 0 to 3275
Data columns (total 10 columns):
 #   Column           Non-Null Count  Dtype  
---  ------           --------------  -----  
 0   ph               3276 non-null   float64
 1   Hardness         3276 non-null   float64
 2   Solids           3276 non-null   float64
 3   Chloramines      3276 non-null   float64
 4   Sulfate          3276 non-null   float64
 5   Conductivity     3276 non-null   float64
 6   Organic_carbon   3276 non-null   float64
 7   Trihalomethanes  3276 non-null   float64
 8   Turbidity        3276 non-null   float64
 9   Potability       3276 non-null   int64  
dtypes: float64(9), int64(1)
memory usage: 256.1 KB
```

- Veri setinin ortalaması, standart sapması hesaplamak için
- df.describe().T kullanıyoruz.

	count	mean	std	min	25%	50%	75%	max
ph	3276.0	7.080345	1.466368	0.000000	6.283265	7.080795	7.865260	14.000000
Hardness	3276.0	196.284533	32.803464	47.432000	176.724139	196.778920	216.576645	323.124000
Solids	3276.0	21981.372303	8599.331395	2552.962804	15715.740730	20988.258608	27286.909002	53735.899194
Chloramines	3276.0	7.122298	1.576932	0.352000	6.133588	7.121371	8.110201	13.127000
Sulfate	3276.0	333.716944	35.813602	180.206746	316.775351	333.775777	350.207431	481.030642
Conductivity	3276.0	426.820402	81.631990	181.483754	365.842780	422.033283	482.303317	695.369528
Organic_carbon	3276.0	14.261592	3.319246	2.200000	12.033868	14.201611	16.542410	28.300000
Trihalomethanes	3276.0	66.398835	15.743965	0.738000	56.714388	66.396293	76.632089	124.000000
Turbidity	3276.0	3.966010	0.779624	1.450000	3.440832	3.950917	4.499166	6.739000
Potability	3276.0	0.391941	0.488258	0.000000	0.000000	0.000000	1.000000	1.000000

- İçilebilirlik oranına bakmak için
- df.Potability.value_counts() kullanıyoruz
- 0 1992
- 1 1284

- X girdisini ve y çıktısını oluşturuyoruz
- X=df.drop("Potability",axis=1)
- y=df["Potability"]

- Daha sonra girdi verisindeki sayısal değişkenlerin ikili saçılım grafiklerini çizdirelim.
- sns.pairplot(X);

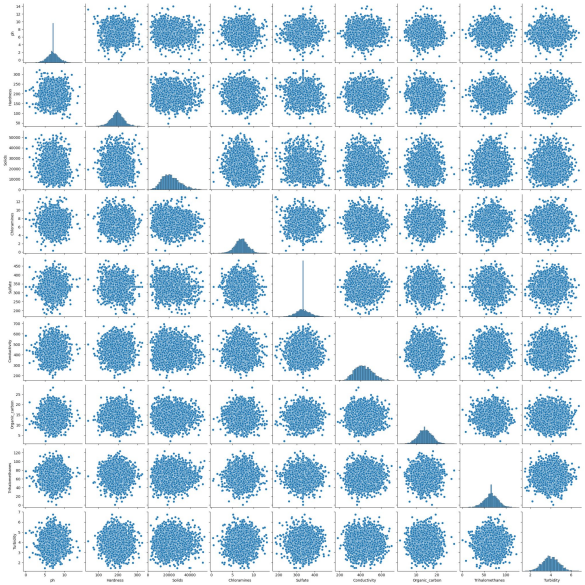

- Korelasyona bakmak için
- corr = df.corr()
- print(corr) kullanıyoruz
-

```
                      ph  Hardness    Solids  Chloramines   Sulfate  \
ph              1.000000  0.075947 -0.084071    -0.028882  0.019745
Hardness        0.075947  1.000000 -0.041262    -0.028854 -0.094008
Solids         -0.084071 -0.041262  1.000000    -0.063214 -0.139035
Chloramines    -0.028882 -0.028854 -0.063214     1.000000  0.015921
Sulfate         0.019745 -0.094008 -0.139035     0.015921  1.000000
Conductivity    0.014047 -0.032427  0.011755    -0.024299 -0.017366
Organic_carbon  0.043010  0.008088  0.012807    -0.011745  0.028066
Trihalomethanes 0.003790 -0.015453 -0.007261     0.018298 -0.026874
Turbidity      -0.037039 -0.013786  0.017439     0.005088 -0.006122
Potability     -0.005718 -0.017380  0.035616     0.022983 -0.023541

                Conductivity  Organic_carbon  Trihalomethanes  Turbidity  \
ph                  0.014047        0.043010         0.003790  -0.037039
Hardness           -0.032427        0.008088        -0.015453  -0.013786
Solids              0.011755        0.012807        -0.007261   0.017439
Chloramines        -0.024299       -0.011745         0.018298   0.005088
Sulfate            -0.017366        0.028066        -0.026874  -0.006122
Conductivity        1.000000        0.002691         0.004118   0.002434
Organic_carbon      0.002691        1.000000        -0.013972  -0.022177
Trihalomethanes     0.004118       -0.013972         1.000000  -0.021934
Turbidity           0.002434       -0.022177        -0.021934   1.000000
Potability          0.006114       -0.035499         0.008273  -0.002138

                Potability
ph               -0.005718
Hardness         -0.017380
Solids            0.035616
Chloramines       0.022983
Sulfate          -0.023541
Conductivity      0.006114
Organic_carbon   -0.035499
Trihalomethanes   0.008273
Turbidity        -0.002138
Potability        1.000000
```

- Test ve Train oluşturmak için sklearn kütüphanesinden çağırıyoruz
- from sklearn.model_selection import train_test_split
- X_train,X_test,y_train,y_test=train_test_split(X,y,test_size=0.25,random_state=100)
- print(X_train.shape)
- print(X_test.shape)
- print(y_train.shape)
- print(y_train.shape)

- Logistic Regression
- from sklearn.linear_model import LogisticRegression çağırıyoruz
- lg_model=LogisticRegression()
- lg_model.fit(X_train,y_train)
- lg_model.score(X_test,y_test)
- 0.6056166056166056
- lg_model.score(X_train,y_train)
- 0.6084656084656085

- Confusion Matrix
- from sklearn.metrics import confusion_matrix
- tahmin=lg_model.predict(X_test)
- confusion_matrix(y_test,tahmin)
- confusion_matrix(y_test,tahmin)
- array([[496, 1],
- [322, 0]],
-

- Naive Bayes
- from sklearn.naive_bayes import GaussianNB kullanıyoruz
- model=GaussianNB()
- nb_b=model.fit(X_train,y_train)
- nb_b.predict(X_test)[0:10] on tahmin yapar
- tahmin=nb_b.predict(X_test)
- confusion_matrix(y_test,tahmin)
- array([[445, 52],
- [252, 70]],)
- y_pred=nb_b.predict(X_test)
- from sklearn.metrics import accuracy_score ile sonuçları ölçüyoruz
- accuracy_score(y_test,y_pred)
- 0.6288156288156288

- KNN en yakın komşu uzaklığı hesaplama
- from sklearn.neighbors import KNeighborsClassifier
- knn=KNeighborsClassifier()
- knn_model=knn.fit(X_train,y_train) knn_model
- y_pred=knn_model.predict(X_test)
- accuracy score'nu hesaplıyoruz
- accuracy_score(y_test,y_pred)
- 0.5641025641025641
- 3 en yakın komşuluk sayısına göre
- reg=KNeighborsClassifier(n_neighbors=3)
- reg.fit(X_train,y_train)
- Doğruluk oranı
- reg.score(X_test,y_test)
- 0.5427435387673957

- import matplotlib.pyplot as plt
- Matplotlib kullanarak KNN'in grafiğini çıkarıyoruz
-

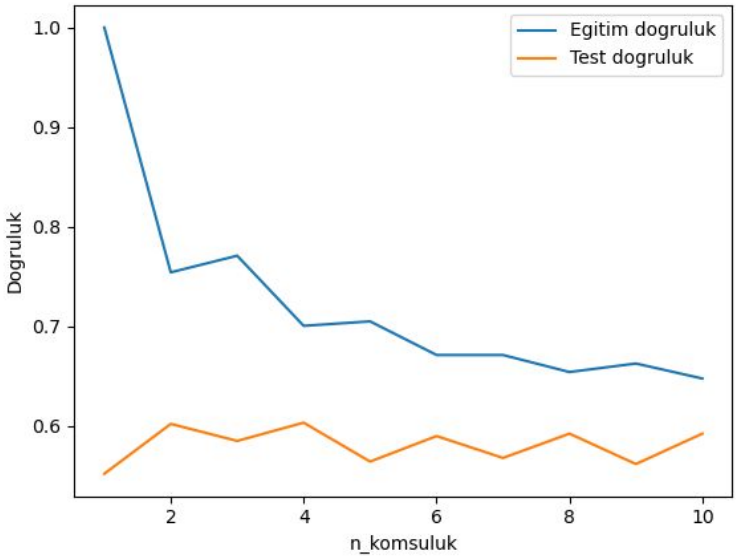

- Karar Ağaçları oluşturma
- from sklearn.tree import DecisionTreeClassifier
- tree = DecisionTreeClassifier()
- tree.fit(X_train,y_train)
- Eğitim ve test verisi doğruluğu
- print(tree.score(X_train,y_train))
- print(tree.score(X_test,y_test))
- 1.0
- 0.6123260437375746

- Kmeans Algoritması
- Benzer özellikleri kümeler import ediyoruz
- from sklearn.cluster import KMeans
- kmeans=KMeans(n_clusters=4)
- kmeans.fit(X)
- verileri tahmin ediyoruz
- labels = kmeans.predict(X)
- labels
- array([0, 0, 2, ..., 3, 2, 1])
-

- Random Forest farklı karar ağaçları için
- from sklearn.ensemble import RandomForestClassifier
- rf = RandomForestClassifier(n_estimators=100, random_state=42)
- rf.fit(X_train, y_train)
- y_pred = rf.predict(X_test)
- accuracy = rf.score(X_test, y_test)
- print("Accuracy:", accuracy)
- 0.6495726495726496

- SVC veri setinde verileri iki sınıfa ayırmak için
- from sklearn.svm import SVC
- svc = SVC(kernel='linear')
- svc.fit(X_train, y_train)
- y_pred = svc.predict(X_test)
- from sklearn.metrics import accuracy_score
- acc = accuracy_score(y_test, y_pred)
- print("Accuracy: ", acc)
- Accuracy: 0.6080586080586081

- En iyi KNN bulabilmek için
- from sklearn.neighbors import KNeighborsClassifier
- from sklearn.model_selection import GridSearchCV
- param_grid = {'n_neighbors':[3,5,7,9], 'metric': ['euclidean', 'manhattan']}
- knn = KNeighborsClassifier()
- grid_search = GridSearchCV(knn, param_grid, cv=5)
- grid_search.fit(X_train, y_train)
- print("En iyi hiperparametreler: ", grid_search.best_params_)
- best_train_score = grid_search.score(X_train, y_train)
- best_test_score = grid_search.score(X_test, y_test)
- print("Eğitim skoru:", best_train_score)
- print("Test skoru:", best_test_score)
- En iyi hiperparametreler: {'metric': 'manhattan', 'n_neighbors': 9}
- Eğitim skoru: 0.6621896621896622
- Test skoru: 0.5787545787545788

Karşılaştırılmaları

```
lr = LogisticRegression()
nb = GaussianNB()
dt = DecisionTreeClassifier()
rf = RandomForestClassifier()
svm = SVC()
knn = KNeighborsClassifier()
# Algoritmaları eğitme
lr.fit(X_train, y_train)
nb.fit(X_train, y_train)
dt.fit(X_train, y_train)
rf.fit(X_train, y_train)
svm.fit(X_train, y_train)
knn.fit(X_train, y_train)
# Performanslarını karşılaştırma
y_pred_lr = lr.predict(X_test)
y_pred_nb = nb.predict(X_test)
y_pred_dt = dt.predict(X_test)
y_pred_rf = rf.predict(X_test)
y_pred_svm = svm.predict(X_test)
y_pred_knn = knn.predict(X_test)
```

```
acc_lr = accuracy_score(y_test, y_pred_lr)
acc_nb = accuracy_score(y_test, y_pred_nb)
acc_dt = accuracy_score(y_test, y_pred_dt)
acc_rf = accuracy_score(y_test, y_pred_rf)
acc_svm = accuracy_score(y_test, y_pred_svm)
acc_knn = accuracy_score(y_test, y_pred_knn)

print("Logistic Regression accuracy: ", acc_lr)
print("Naive Bayes accuracy: ", acc_nb)
print("Decision Tree accuracy: ", acc_dt)
print("Random Forest accuracy: ", acc_rf)
print("Support Vector Machine accuracy: ", acc_svm)
print("K-Nearest Neighbors accuracy: ", acc_knn)
```

```
Logistic Regression accuracy:  0.6056166056166056
Naive Bayes accuracy:  0.6288156288156288
Decision Tree accuracy:  0.5714285714285714
Random Forest accuracy:  0.6556776556776557
Support Vector Machine accuracy:  0.6068376068376068
K-Nearest Neighbors accuracy:  0.5641025641025641
```

Yapay Sinir Ağları

- Oluşturmak için tensorflow import ediyoruz
- import tensorflow as tf

- Daha sonra çıktı eğitim ve çıktı test verilerini one-hot kodlayalım.
- y_train=tf.keras.utils.to_categorical(y_train)
  y_test=tf.keras.utils.to_categorical(y_test)
- ilk beş satır
- y_train[:5,:]
- array([[1., 0.], [0., 1.], [0., 1.], [1., 0.], [0., 1.]], dtype=float32)

- numpy array yapısına çeviriyoruz
-
- X_train=X_train.values
  X_test=X_test.values
- Sequential sınıfını import edelim.
- from tensorflow.keras.models import Sequential
- Dense sınıfını import edelim.
- from tensorflow.keras.layers import Dense
- model=Sequential()

- 2 kategori olduğu için bu layerdaki nöron sayısı 2 ve aktivasyon fonksiyonu olarak sigmoid.
- model.add(Dense(64,activation="relu",
  input_shape=X_train[0].shape))
  model.add(Dense(128,activation="relu"))
  model.add(Dense(128,activation="relu"))
  model.add(Dense(128,activation="relu"))
  model.add(Dense(128,activation="relu"))
  model.add(Dense(64,activation="relu"))
  model.add(Dense(64,activation="relu"))
  model.add(Dense(64,activation="relu"))
  model.add(Dense(64,activation="relu"))
  model.add(Dense(2,activation="sigmoid")

- ne kadar iyi tahmin yaptığı
- model.compile(optimizer="adam",
  loss="categorical_crossentropy",
  metrics=["acc"])
- history=model.fit(X_train,y_train,
  batch_size=32,
  epochs=7,
  validation_split=0.1)

```
Epoch 1/7
70/70 [==============================] - 1s 9ms/step - loss: 8.5150 - acc: 0.5075 - val_loss: 9.3521 - val_acc: 0.4268
Epoch 2/7
70/70 [==============================] - 0s 4ms/step - loss: 3.8137 - acc: 0.4966 - val_loss: 4.3418 - val_acc: 0.4268
Epoch 3/7
70/70 [==============================] - 0s 4ms/step - loss: 2.6346 - acc: 0.5138 - val_loss: 1.2779 - val_acc: 0.5732
Epoch 4/7
70/70 [==============================] - 0s 4ms/step - loss: 1.0462 - acc: 0.5328 - val_loss: 0.6872 - val_acc: 0.5732
Epoch 5/7
70/70 [==============================] - 0s 5ms/step - loss: 0.7566 - acc: 0.5540 - val_loss: 0.7212 - val_acc: 0.5732
Epoch 6/7
70/70 [==============================] - 0s 5ms/step - loss: 0.7546 - acc: 0.5563 - val_loss: 0.7392 - val_acc: 0.5732
Epoch 7/7
70/70 [==============================] - 0s 4ms/step - loss: 0.7250 - acc: 0.5568 - val_loss: 0.7941 - val_acc: 0.4309
```

- model.evaluate(X_test,y_test)

```
26/26 [==============================] - 0s 2ms/step - loss: 0.8010 - acc: 0.3956

[0.8010177612304688, 0.3956044018268585]
```

Bitti

kaynak:https://www.kaggle.com/datasets/adityakadiwal/water-potability